

引文格式: 杭仁龙, 李成相, 刘青山. 谱间对比学习的高光谱图像无监督特征提取[J]. 测绘学报, 2023, 52(7): 1164–1174. DOI:10.11947/j. AGCS.2023.20220493.

HANG Renlong, LI Chengxiang, LIU Qingshan. Inter — spectral contrast learning based unsupervised feature extraction for hyperspectral images[J]. Acta Geodaetica et Cartographica Sinica, 2023, 52(7): 1164–1174. DOI:10.11947/j. AGCS.2023.20220493.

谱间对比学习的高光谱图像无监督特征提取

杭仁龙^{1,2}, 李成相^{1,2}, 刘青山^{1,2}

1. 南京信息工程大学计算机学院, 江苏 南京 210044; 2. 江苏省大气环境与装备技术协同创新中心, 江苏 南京 210044

Inter — spectral contrast learning based unsupervised feature extraction for hyperspectral images

HANG Renlong^{1,2}, LI Chengxiang^{1,2}, LIU Qingshan^{1,2}

1. School of Computer, Nanjing University of Information Science and Technology, Nanjing 210044, China;
2. Jiangsu Collaborative Innovation Center of Atmospheric Environment and Equipment Technology, Nanjing 210044, China

Abstract: Deep learning is able to extract high — level features from input data via layer by layer abstraction. In recent years, it has been widely used in hyperspectral image classification. Most of the existing deep learning — based feature extraction methods for hyperspectral images belong to supervised learning models, which require a large number of labeled samples in the training process, but it is difficult and time — consuming to label hyperspectral images pixel by pixel. Therefore, we propose an unsupervised deep learning model based on inter — spectral contrast learning in this paper. It can extract features by modeling the relationship between different spectral bands without annotation of samples. Specifically, because different spectral channels of hyperspectral image depict the response degree of the same object in different electromagnetic spectrum, there must be a feature space, which makes the spectral information of different channels have similar characterization. Inspired by this, we first divide the high — dimensional spectral information into two groups, and then extract the features of each group using multi — layer convolution operations. Finally, the features extracted from different samples are compared and a contrastive loss function is constructed to optimize the model parameters. To test the performance of the proposed model, it was applied to a hyperspectral image classification task and validated on three commonly used data sets, including Houston 2013, Pavia University and WHU — Hi — Longkou. Experimental results show that using only 10 training samples in each class, the proposed unsupervised learning model can obtain better classification performance than the commonly used unsupervised models such as principal component analysis and auto — encoder.

Key words: unsupervised learning; deep learning; hyperspectral image; feature extraction

Foundation support: The National Key Research and Development Program of China(No. 2021ZD0112200); The National Natural Science Foundation of China(Nos. U21B2044; U21B2049; 61906096)

摘 要:深度学习通过逐层抽象的方式提取输入数据的深层特征,近年来在高光谱图像分类领域得到了广泛的应用。现有的高光谱图像深度特征提取方法大多属于有监督学习模型,其训练过程需要大量标记样本,而高光谱图像逐像素的标注困难且费时。为此,本文提出了一种基于谱间对比学习的无监督深度学习模型。无须对样本进行标注,仅通过建模不同光谱波段之间的关系便可实现特征提取。具体而言,由于高光谱图像不同的光谱通道刻画了同一物体在不同电磁波段的响应程度,因此必然存在一个特征空间,使得不同通道的光谱信息具有相似的表征。受此启发,本文首先将高维光谱信息分成两组,然

后利用多层卷积操作分别提取每组波段的特征,最后对比不同样本所提取的特征,通过对比损失函数来优化模型。为了测试本文方法的性能,将其应用于高光谱图像分类任务中,在 Houston 2013、Pavia University 和 WHU—Hi-Longkou 3 个常用的数据集上进行了验证。试验结果表明,在每类仅使用 10 个训练样本的前提下,本文所提出的无监督学习模型能够获得比主成分分析、自编码器等常见的无监督模型更优越的分类性能。

关键词:无监督学习;深度学习;高光谱图像;特征提取

中图分类号:P237

文献标识码:A

文章编号:1001-1595(2023)07-1164-11

基金项目:科技创新 2030—“新一代人工智能”重大项目(2021ZD0112200);国家自然科学基金(U21B2044;U21B2049;61906096)

高光谱图像通常由数十至数百个波段构成,每个波段刻画了目标区域不同物体的空间分布特征,而不同的波段则记录了同一物体在可见光、近红外、中红外等光谱波段的反射或辐射信息。如此丰富的光谱和空间信息,使得高光谱图像在精准农业、城市规划、资源调查、大气监测等领域有着非常广泛的应用。由于高光谱图像光谱维度高且相邻波段之间存在冗余性,因此如何从高维冗余的信息中提取有效的特征是其应用过程中需要解决的关键问题。

与传统的特征提取方法不同,深度学习通过逐层抽象的方式,能够从高维复杂数据中自主学习深层特征表示,自 2014 年被引入高光谱领域后^[1],逐渐成为高光谱图像特征提取的主流方法^[2-6]。例如,文献[7]采用一维卷积神经网络提取光谱特征;文献[8-9]将高光谱图像看作一个光谱序列,通过循环神经网络提取光谱特征;文献[10]通过二维卷积神经网络提取高光谱图像的空间特征;文献[11-12]分别利用三维卷积神经网络和胶囊网络提取高光谱图像的谱-空联合特征。上述方法大多属于监督学习模型,需要大量的标记样本对网络进行训练,才能提取有效的判别特征,但高光谱图像逐像素的标注困难且费时。为此,研究人员利用无监督特征提取网络来解决该问题。与监督学习模型不同,无监督学习不需要标记样本,可以直接从未标注样本中提取特征。

自编码器(autoencoder, AE)是典型的高光谱图像无监督特征提取网络之一^[1],首先通过编码器提取输入数据的特征,然后通过解码器从该特征重构原始输入。传统自编码器的输入为一维向量,可以直接提取高光谱图像的光谱特征,但无法有效提取谱-空联合特征。为了解决该问题,文献[13-16]提出了卷积自编码器模型(CAE),分别通过多个卷积层和反卷积层构建编码器和解码

器。在此基础上,文献[17]利用生成对抗网络,提升了 CAE 的重构能力,从而提取了更为有效的特征。除了基于 AE 的模型外,近年来基于对比学习的无监督特征提取方法受到了越来越多的关注^[18-20],其核心思想是对给定的输入图像,通过一定的数据增强方法(如裁剪、缩放、颜色失真等)获取样本对,并假设其在特征空间的距离小于该图像与其他图像的距离。例如,文献[21]通过添加随机噪声的方式构造样本对,并将对比学习的思想引入高光谱图像分类任务中。与此同时,文献[22]通过裁剪、水平翻转、颜色抖动和高斯模糊 4 种方式构造样本对,并使用残差网络进行对比学习。不同于数据增强的方法,文献[23]对于同一个样本,利用两种不同的特征变换方法构造样本对。

尽管上述两类无监督特征学习方法取得了不错的性能,但是仍然存在一些问题。基于 AE 的方法更加关注数据的重构,无法保证所学特征的判别能力,因而在下游任务中(比如高光谱分类)往往很难取得理想的效果。与之不同,基于对比学习的方法通过比较样本之间的关系,可以获得较好的判别能力,但当前方法主要通过空间变换构造样本对,容易忽视高光谱图像丰富的光谱特征。为了解决上述问题,本文利用高维光谱信息,提出了一种基于谱间对比学习的无监督特征提取方法。本文方法首先将高维光谱波段切分成两组,每组波段可看作同一物体的不同变换,从而形成了一组样本对;然后通过多层卷积操作提取每组样本的特征,并对比不同样本对的距离;最后,通过对比损失优化模型参数。与主流的无监督特征提取方法相比,本文方法在 Houston 2013、Pavia University 和 WHU—Hi-Longkou 3 个常用的数据集上均能取得更优的分类性能。

1 本文方法

图1为本文方法流程,主要由高光谱图像无监督特征提取网络和高光谱图像分类网络两部分组成。对于无监督特征提取网络,首先使用主成分分析(PCA)对高光谱图像降维,以去除冗余的光谱信息,提升计算效率。然后,以每个像素点为中心,截取固定大小的立方块。假设高光谱立方块可表示为 $X^i \in \mathbf{R}^{s \times s \times c}$, $i \in \{1, 2, \dots, N\}$, 其中 s

为立方块的宽和高, c 表示高光谱图像经PCA降维后保留的通道数量,即主成分个数, N 表示立方块的数量。为便于后续处理,本文将 c 取为偶数。最后,将高光谱立方块 X^i 沿着通道维度均匀切分,得到两个子立方块 $X_a^i \in \mathbf{R}^{s \times s \times c_1}$ 和 $X_b^i \in \mathbf{R}^{s \times s \times c_2}$,其中 $c_1 = c_2 = c/2$ 。通过特征提取模块分别提取 X_a^i 和 X_b^i 的特征。在后续试验中,本文将参数 s 和 c 的值分别设为11和20。

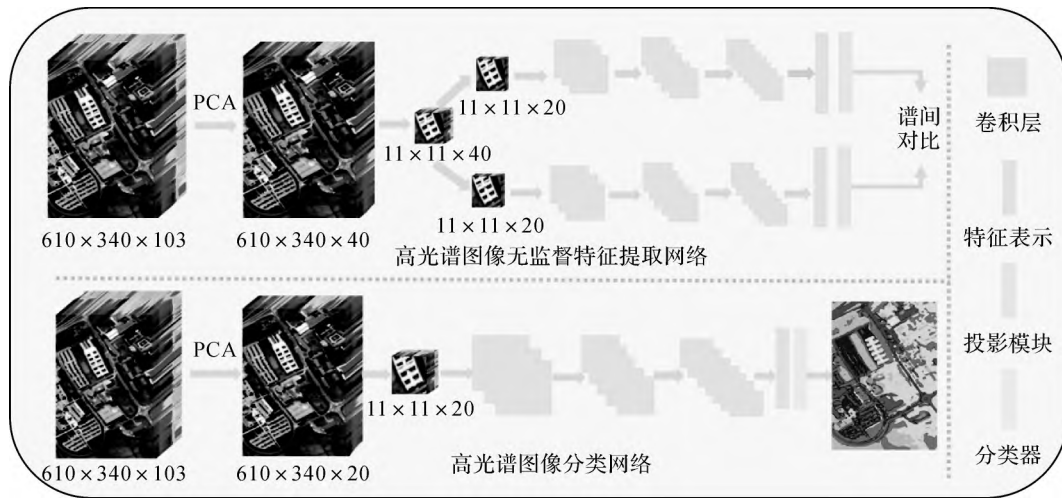


图1 本文方法流程

Fig.1 Flowchart of the proposed method

特征提取模块由3个卷积层构成。每个卷积层包含卷积、批归一化、非线性激活层ReLU和最大池化4个操作。其中,批归一化用于正则化和加速训练过程,ReLU用于学习非线性表示,最大池化用于降低方差和减少计算复杂度。除第一个卷积层外,其余两个卷积层共享参数。表1详细地罗列了不同网络层所包含的操作类型和相应参数的设定情况。由表1可知,3个卷积层的卷积核大小均为 3×3 ,卷积核的个数依次设为32、64和128。卷积特征提取过程可表示为

$$\begin{cases} F_a^{d+1} = \text{Conv}(F_a^d) \\ F_b^{d+1} = \text{Conv}(F_b^d) \end{cases} \quad (1)$$

式中, F_a^{d+1} 和 F_b^{d+1} 表示 $d+1$ 层的输出, $d \in \{0, 1, 2\}$, F_a^0 表示输入图像块 X_a^i , F_b^0 表示输入图像块 X_b^i ;Conv表示卷积运算。

经过特征提取模块后,可生成两个维数相同的特征表示 Z_a^i 和 Z_b^i 。考虑到 Z_a^i 和 Z_b^i 是对同一个物体的不同表示,因此必然存在一个特征隐空间,使得 Z_a^i 和 Z_b^i 之间的距离相近。基于此,本文在特征提取模块后,设计了一个投影模块,以充

分利用上述先验知识。该特征投影模块由全连接层构成,其计算过程可表示为

$$\begin{cases} h_a^i = w^T Z_a^i \\ h_b^i = w^T Z_b^i \end{cases} \quad (2)$$

式中, h_a^i 和 h_b^i 为投影之后的结果; w 表示全连接层的连接权重。在后续试验中,全连接层的神经元个数设为8。

表1 网络结构

Tab.1 Network Structure Diagram

网络层名称	参数设置	步长	输出大小
第一个卷积层	$3 \times 3 \times 32$	1	$11 \times 11 \times 32$
最大池化层	2×2	2	$5 \times 5 \times 32$
第二个卷积层	$3 \times 3 \times 64$	1	$5 \times 5 \times 64$
最大池化层	2×2	2	$2 \times 2 \times 64$
第三个卷积层	$3 \times 3 \times 128$	1	$2 \times 2 \times 128$
最大池化层	2×2	2	$1 \times 1 \times 128$
投影模块	8	-	8
分类器	类别数	-	类别数

除了网络结构外,损失函数的构建对无监督特征提取网络同样至关重要。为了使 h_a^i 和 h_b^i 之

间满足距离相近的假设,受文献[18]启发,本文设计了一个对比损失函数 L

$$L = -\frac{1}{N} \sum_{i=1}^N \ln \frac{\exp(\text{sim}(\mathbf{h}_a^i, \mathbf{h}_b^i)/\tau)}{\Pi} \quad (3)$$

式中,变量 Π 为 $\sum_{j=1}^N 1_{[j \neq i]} [\exp(\text{sim}(\mathbf{h}_a^i, \mathbf{h}_b^j)/\tau) + \exp(\text{sim}(\mathbf{h}_b^i, \mathbf{h}_a^j)/\tau)]$, $1_{[j \neq i]} \in \{0, 1\}$ 为指示函数,且当 $j \neq i$ 时,该指示函数的取值为 1,否则为 0, τ 是一个可调节的超参数,本文根据经验将其设置为 1。函数 $\text{sim}(\cdot, \cdot)$ 用于计算输入的两个向量之间的余弦相似度,其表达式为 $\text{sim}(\mathbf{x}, \mathbf{y}) = \mathbf{x}^T \mathbf{y} / \|\mathbf{x}\| \|\mathbf{y}\|$, $\|\cdot\|$ 表示向量的模。余弦相似度通过测量两个向量夹角的余弦值来判断是否相似。若余弦值接近 1,夹角趋于 0° ,两个向量相似;余弦值接近 0,夹角趋于 90° ,两个向量不相似。 N 中的每个图像块仅有一组正样本,其余均为负样本。由于整个损失函数未涉及任何标注信息,因此可以最大限度地挖掘高光谱图像中丰富的未标注样本信息,提取更为通用的特征,以更好地为下游任务服务。

为了验证所提特征的表示能力,通常将其应用于高光谱图像分类任务中。为此,本文在特征提取网络的基础上,构建了高光谱分类网络,如图 1 下半部分所示,其网络结构与特征提取网络相似,同样由 PCA 和特征提取模块构成。值得注意的是,此时 PCA 保留的主成分个数为 $c/2$,因此可以直接迁移特征提取网络中训练得到的 3 层卷积参数。在分类阶段,通过一层全连接层构建分类器,其神经元个数由高光谱图像中地物类别个数决定。此外,为了使分类网络获得足够多的判别信息,除了直接迁移模型参数外,还需要使用少量标记样本对参数进行微调。不失一般性,本文使用交叉熵损失函数 L_{CE} 对分类网络进行微调

$$L_{CE} = -\frac{1}{S} \sum_{g=1}^S \sum_{m=1}^M T_{gm} \ln(P_{gm}) \quad (4)$$

式中, S 表示标记样本个数; M 表示高光谱图像中地物类别个数; P_{gm} 为分类模型的预测结果; T_{gm} 为真实标签。

2 试验结果与分析

2.1 试验数据

为验证本文方法的有效性,采用 3 个高光谱数据集进行试验,分别为 Houston 2013 数据集、Pavia University 数据集和 WHU-Hi-Longkou 数

据集。表 2 给出了高光谱数据集的详细信息。

表 2 本文采用的高光谱数据集信息

Tab.2 Information of the adopted hyperspectral datasets

数据名称	Houston 2013	Pavia University	WHU-Hi-Longkou
影像大小/像素	349×1905	610×340	550×400
传感器	ITRES-CASI1500	ROSIS	Nano-Hyperspec
波段数	144	103	270
光谱范围/ μm	0.38~1.05	0.43~0.86	0.4~1
空间分辨率	2.5	1.3	0.463
地物类别数量	15	9	9

(1) Houston 2013 数据集于 2012 年 6 月在休斯敦大学校园和邻近地区获取。该图像包含 349×1905 像素,有 15 种土地覆盖物。该数据集拥有 144 个光谱波段,覆盖的波长范围为 $0.38 \sim 1.05 \mu\text{m}$ 。

(2) Pavia University 数据集是在 2002 年意大利北部帕维亚上空的一次飞行比赛中通过 ROSIS 传感器获得的图像。数据集的图像大小为 610×340 像素,空间分辨率为 1.3 m。原始图像记录了 115 个光谱通道,范围为 $0.43 \sim 0.86 \mu\text{m}$ 。去除 12 个噪声波段后,使用 103 个波段用于分类。该数据集包含 9 类土地覆盖物,每一类的标签样本数均超过 1000 个。

(3) WHU-Hi-Longkou 数据集^[24]由安装在大疆 Matrice 600 Pro(DJI M600 Pro)无人机平台上的 8 mm 焦距 Headwall Nano-Hyperspec 成像传感器获得。研究区域为中国湖北省龙口镇的一个农业场景,包括玉米、棉花、芝麻、宽叶大豆、窄叶大豆和水稻 6 种作物。无人机飞行时间为 2018 年 7 月 17 日,飞行高度为 500 m,图像尺寸为 550×400 像素,波段范围为 $0.4 \sim 1 \mu\text{m}$,波段个数为 270,图像空间分辨率约为 0.463 m。

2.2 试验设置

本文试验的硬件环境为 32GB 内存, Intel Core i7-4790 处理器, GTX TITAN X 显卡, 软件环境为在 Ubuntu 系统下的 Python 3.8.4 和 PyTorch 1.6。

表 3—表 5 给出了 3 个数据集上数据的划分情况,其中候选样本和测试样本共同用于无监督特征提取网络的训练。此时,批量处理的样本数设置为 256,学习率为 0.000 1,训练周期为 100。在分类任务中,使用每类 10 个样本的训练集对模型进行微调。此时,批量处理的样本数设置为

64,学习率为 0.001,训练周期设为 200。为了有效度量分类性能,本文使用总体精度(OA)、平均精度(AA)、每类精度和 Kappa 系数作为度量指标。其中,OA 定义了正确分类像素的数量和像素的总数之间的比例;AA 指的是所有类准确率的平均值。本文选择 4 种常用的无监督特征提取方法(包括 PCA、EMP、AE 和 CAE)、基于 CNN 的监督特征提取方法以及基于生成对抗网络(GAN)的半监督特征提取方法 MTGAN 作为对比模型,具体介绍如下。

(1) PCA_RF,首先采用 PCA 从高光谱图像中提取光谱特征,然后采用包含 10 棵树的随机森林对提取的特征进行分类。

(2) EMP_SVM,首先利用 PCA 对高光谱图像降维,然后采用形态学开/闭操作进行特征提取,最后使用核支持向量机得到分类结果。

(3) AE,由一个编码器和一个解码器组成,两者都包含 3 个全连接层。

(4) CAE 采用 3 个卷积层和 3 个反卷积层来构建网络。

(5) MTGAN,该模型由文献[25]提出,利用 GAN 网络同时进行重构和分类,本文采用相同的网络结构。

(6) CNN-F-20,该网络结构与本文提出的分类模型相同,但没有使用无监督对比学习模型。

(7) CNN-F-40,该网络结构与 CNN-F-20 相同,只是将输入通道个数从 20 改为 40。

表 3 Houston 2013 数据集划分情况

Tab.3 Division of Houston 2013 dataset

类别序号	地物类别	训练样本	候选样本	测试样本
1	健康草坪	10	198	1053
2	受损草坪	10	190	1064
3	合成草坪	10	192	505
4	树木	10	188	1056
5	土壤	10	186	1056
6	水	10	182	143
7	居住区	10	196	1072
8	商业区	10	191	1053
9	道路	10	193	1059
10	高速公路	10	191	1036
11	铁路	10	182	1054
12	停车场 1	10	192	1041
13	停车场 2	10	184	285
14	网球场	10	182	247
15	跑道	10	187	473
总数		150	2832	12 197

表 4 Pavia university 数据集划分情况

Tab.4 Division of Pavia University dataset

类别序号	地物类别	训练样本	候选样本	测试样本
1	柏油路面	10	548	6631
2	草地	10	540	18 649
3	砖块砂砾	10	392	2099
4	树木	10	524	3064
5	金属板	10	265	1345
6	裸土	10	532	5029
7	沥青屋顶	10	375	1330
8	砖块	10	514	3682
9	阴影	10	231	947
总数		90	3921	42 776

表 5 WHU-Hi-Longkou 数据集划分情况

Tab.5 Division of WHU-Hi-Longkou dataset

类别序号	地物类别	训练样本	候选样本	测试样本
1	玉米	10	300	34 211
2	棉花	10	300	8074
3	芝麻	10	300	2731
4	原叶大豆	10	300	62 912
5	长叶大豆	10	300	3851
6	水稻	10	300	11 554
7	水体	10	300	66 756
8	房屋和道路	10	300	6824
9	混合杂草	10	300	4929
总数		90	2700	201 842

2.3 试验结果

不同的特征提取方法在 Houston 2013 数据集上的分类结果见表 6。与 PCA、EMP、AE 和 MTGAN 相比,CAE 能够取得最好的性能,其 OA 和 Kappa 系数均达到最高值。尽管如此,本文方法的 OA 值高达 81.04%、AA 值高达 83.64%、Kappa 系数为 79.42%。这 3 个指标依次比 CAE 对应指标高约 6%、5%和 6%。同时,为了体现无监督特征表示过程的有效性和必要性,本文与 CNN-F-20 和 CNN-F-40 进行了对比,结果如表 6 倒数第 3 和第 2 列所示。从中可以发现,使用基于谱间对比学习的无监督特征提取网络,可将 CNN-F-20 的 OA 值提高约 2.5%,AA 值提高约 2%,Kappa 系数提高约 3%。当与 CNN-F-40 相比时,本文方法的分类性能依然是最好的,3 个指标依次高约 1.2%、1.6%和 1.3%。此外,在 15 个地物类别中本文方法在 5 个类别上能够获得最高的分类精度。图 2 展示了 Houston 2013 数据集上不同方法的可视化结果,与图 2(b)相比,本文方法能够获得更一致的分类结果。上述试验结果充分证明了本文方法在 Houston

2013 数据集上的有效性。

表 6 不同方法在 Houston 2013 数据集上的分类结果

Tab.6 Classification results of different methods on Houston 2013 dataset

类别序号	PCA_RF	EMP_SVM	AE	CAE	MTGAN	CNN-F-20	CNN-F-40	本文方法
1	82.53	81.29	81.37	86.70	77.78	82.53	83.19	84.43
2	97.46	99.25	62.88	98.68	96.43	99.25	99.72	99.72
3	93.07	99.60	78.22	88.91	93.47	93.66	93.86	97.03
4	92.14	79.26	90.63	97.16	85.23	98.96	98.11	97.92
5	86.74	80.21	78.13	99.81	98.30	100	100	100
6	77.62	94.41	57.34	91.61	88.81	94.41	95.80	93.00
7	45.99	43.00	67.16	49.72	63.90	70.80	67.07	71.92
8	53.47	67.71	51.00	55.65	65.34	57.17	68.66	78.25
9	77.24	76.68	56.85	66.95	75.26	68.65	72.33	66.57
10	29.05	28.86	27.12	48.26	29.25	31.66	40.83	32.63
11	90.70	89.37	57.50	62.90	74.00	68.79	82.35	92.13
12	36.79	47.93	66.19	61.19	48.61	84.82	68.11	65.99
13	76.14	67.37	21.40	84.56	90.53	83.16	88.42	83.16
14	92.31	96.36	64.78	85.02	98.38	93.52	78.95	96.76
15	98.94	100	68.92	99.79	100	93.66	92.18	95.14
OA/(%)	72.17	72.67	63.68	75.21	74.73	78.45	79.78	81.04
AA/(%)	75.35	76.75	61.97	78.46	79.02	81.40	81.97	83.64
Kappa 系数/(%)	69.84	70.41	60.48	73.13	72.61	76.63	78.08	79.42




图 2 Houston 2013 数据集上不同方法的分类结果

Fig.2 Classification maps of different methods on Houston 2013 dataset

Pavia University 数据集的分类结果见表 7。在 4 种基于无监督特征提取的对比方法中,CAE 方法的 OA 值最高,能够取得最好的分类效果,该结果也优于半监督学习模型 MTGAN,因为卷积网络能够同时捕获高光谱图像的非线性结构和谱

空联合特征。与所有对比方法相比,本文方法的 OA、AA 及 Kappa 系数的值最高。具体而言,OA 为 75.78%,比 CAE 高约 3%;AA 为 82.76%,比 CAE 高约 10%;Kappa 系数为 69.66%,相比于 CAE,提高了约 6%。此外,由表 7 倒数第 3 列可

以看出,不使用无监督特征提取网络时,OA 值下降为 69.13%,与本文方法相比下降了约 6%;AA 值下降了约 5%;Kappa 系数下降了约 8%。与 CNN-F-40 相比,本文方法在3 类指标中依次提升约 6%、5%和 8%。Pavia University 数据集的分类结果如图 3 所示,从中可以看出本文方法的分类效果优于其他方法。

表 7 不同方法在 Pavia university 数据集上的分类结果
Tab.7 Classification results of different methods on Pavia University dataset

类别序号	PCA_RF	EMP_SVM	AE	CAE	MTGAN	CNN-F-20	CNN-F-40	本文方法
1	64.08	68.32	53.04	79.48	89.73	59.09	55.35	61.42
2	43.57	60.57	79.69	84.03	42.44	69.05	77.95	72.72
3	67.03	66.79	30.01	50.17	53.17	62.51	75.70	76.89
4	96.83	96.12	26.53	92.40	93.24	97.32	95.79	91.06
5	99.85	99.55	53.75	99.93	99.33	100	99.85	99.93
6	95.61	44.30	49.55	26.94	98.41	58.14	33.05	89.10
7	95.34	97.44	75.79	77.44	86.39	86.84	85.71	87.59
8	68.25	47.28	63.80	45.49	83.46	66.46	47.69	66.38
9	100	100	14.57	98.63	95.03	99.79	99.16	99.79
OA/(%)	64.59	64.81	62.03	72.85	68.37	69.91	69.13	75.78
AA/(%)	81.17	75.60	49.63	72.73	82.36	77.69	74.47	82.76
Kappa 系数/(%)	57.83	55.96	49.57	63.90	62.26	61.93	59.95	69.66




图 3 Pavia University 数据集上不同方法的分类结果
Fig.3 Classification maps of different methods on Pavia University dataset

WHU-Hi-Longkou 数据集的分类结果见表 8。与 4 种无监督特征提取方法相比,本文方法取得了最佳性能。其中,OA 为 98.24%,AA 为 95.87%,Kappa 系数为 97.69%。与分类效果较为理想的 CAE 相比,本文方法的 OA 值提高了 2.73%,AA 值提高了 0.94%,Kappa 系数提高了

3.55%。图 4 为 WHU-Hi-Longkou 数据集的分类结果,进一步说明了本文方法的有效性。

表 8 不同方法在 WHU-Hi-Longkou 数据集上的分类结果
Tab.8 Classification results of different methods on WHU-Hi-Longkou dataset

类别序号	PCA_RF	EMP_SVM	AE	CAE	MTGAN	CNN-F-20	CNN-F-40	本文方法
1	99.56	90.46	99.41	99.62	99.87	99.84	99.83	99.88
2	88.22	80.36	78.60	96.80	99.64	98.60	99.95	97.93
3	95.20	87.92	90.63	94.87	87.62	97.80	99.01	96.59
4	86.44	78.52	86.26	88.81	92.23	94.18	93.21	97.44
5	66.76	98.29	61.54	96.99	97.14	97.53	93.30	98.44
6	95.02	96.65	94.74	98.77	98.55	99.23	98.51	99.43
7	99.99	99.89	99.97	99.96	99.99	99.96	99.97	99.99
8	87.28	96.38	84.48	91.81	87.81	92.29	90.90	91.00
9	64.29	67.19	70.22	86.77	84.87	79.04	81.70	82.09
OA/(%)	92.94	89.55	92.34	95.51	96.45	97.19	96.86	98.24
AA/(%)	86.98	88.41	85.09	94.93	94.19	95.39	95.15	95.87
Kappa 系数/(%)	90.79	86.57	90.02	94.14	95.35	96.32	95.89	97.69




图 4 WHU-Hi-Longkou 数据集上不同方法的分类结果
Fig.4 Classification maps of different methods on WHU-Hi-Longkou dataset

2.4 主成分数量对结果的影响

本文提出的无监督学习框架中需要预先设定主成分个数,为了评估其对最终结果的影响,选取 5、10、15、20、25 和 30 作为候选值,在 3 个数据集上进行了测试。试验结果如图 5 所示。在 Houston 2013 数据集上可以直观地看出,当主成分个数等于 20 时,OA、AA 和 Kappa 系数均取得最高值。在 Pavia University 数据集上,当主成分个数为 20 时,OA 和 Kappa 系数与主成分个数为 5 时相比,稍有下降,但是 AA 值达到了最高

值;当主成分个数大于 20 时,OA 和 Kappa 系数出现极速下降。在 WHU-Hi-Longkou 数据集上,仍然可以看出在主成分个数为 20 时,OA、AA、Kappa 系数能够取得最高值。综上所述,考虑 3 个数据集上主成分个数的兼容性,可将其大小设置为 20。

2.5 立方块大小对结果的影响

为了评估不同的立方块大小 s 对试验结果的影响,本文采用 7、9、11、13、15、17 和 19 共 7 个候选值进行了对比试验,试验结果如图 6 所示。从

中可以看出,当输入立方块尺寸从 7 逐渐增加到 11 时,OA、AA 和 Kappa 系数均出现了明显的提高,在 Houston 2013 数据集上表现最为明显。当图像块尺寸大于 11 时,所有数据集的结果均出现一定程度的下降,但在 WHU-Hi-Longkou 数据

集上图像块尺寸为 17 和 19 时,AA 值比尺寸为 11 时略高,但图像块尺寸为 11 时取得了最高的 OA 和 Kappa 值。综上所述,考虑不同数据集上立方块尺寸的兼容性,本文将立方块的大小设为 11。




图 5 不同数据集分类精度随主成分数量大小的变化情况

Fig.5 Classification accuracy of different datasets varies with the principal component quantity




图 6 不同数据集分类精度随立方块大小的变化情况

Fig.6 Classification accuracy of different datasets varies with the patch size

2.6 特征可视化分析

为了分析本文方法所提特征的有效性,采用 t-SNE 算法对最后一层卷积特征进行了可视化,结果如图 7 所示。图中不同颜色代表不同的地物类型,第 1 行和第 2 行分别表示使用谱间对比学习前后的特征分布情况,第 1 列和第 2 列分别为 Pavia University 数据集和 WHU-Hi-Longkou 数据集的可视化结果。从中可以看出,采用本文提出的谱间对比学习模型后,相同类型的地物特征分布更紧凑,不同类型的地物特征区分度更明显,充分验证了本文方法能够提取判别性能更强的特征。

3 结 论

为了解决高光谱图像标注信息难获取的问

题,本文提出了一种基于谱间对比学习的无监督特征提取方法。该方法首先通过主成分分析去除冗余的光谱信息;然后将提取的光谱主成分均匀地切分为两组,并利用多层卷积层提取每组特征;最后将特征投影到度量空间,使得同一物体的两组特征尽可能相近。为了验证本文方法的有效性,将提取的特征应用于分类任务中。在 Houston 2013、Pavia University 和 WHU-Hi-Longkou 3 个数据集上的试验结果表明,本文方法能够获得比常用的主成分分析、形态学特征及自编码器等无监督特征提取方法更好的分类性能。此外,本文还评估了不同的超参数对模型性能的影响,比如主成分的个数、输入立方块的大小。在后续的研究中,可以进一步探索如何构建更好的光谱分组策略和对比损失函数。




图7 不同数据集的特征可视化

Fig.7 Feature visualization on two different datasets

参考文献:

- [1] CHEN Yushi, LIN Zhouhan, ZHAO Xing, et al. Deep learning-based classification of hyperspectral data [J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2014, 7(6): 2094-2107.
- [2] RASTI B, HONG Danfeng, HANG Renlong, et al. Feature extraction for hyperspectral imagery: the evolution from shallow to deep; overview and toolbox[J]. IEEE Geoscience and Remote Sensing Magazine, 2020, 8(4): 60-88.
- [3] 张号达, 李映, 姜晔楠. 深度学习在高光谱图像分类领域的研究现状与展望[J]. 自动化学报, 2018, 44(6): 961-977.
ZHANG Haokui, LI Ying, JIANG Yenan. Deep learning for hyperspectral imagery classification: the state of the art and prospects[J]. Acta Automatica Sinica, 2018, 44(6): 961-977.
- [4] 李云飞, 李军, 贺霖. 单样本对卷积神经网络遥感图像时空融合[J]. 遥感学报, 2022, 26(8): 1614-1623.
LI Yunfei, LI Jun, HE Lin. Convolutional neural network based single image pair method for spatiotemporal fusion [J]. National Remote Sensing Bulletin, 2022, 26(8): 1614-1623.
- [5] 杨星, 池越, 周亚同, 等. 基于光谱-空间注意力双边网络的高光谱图像分类[J/OL]. 遥感学报, [2022-08-10]. <http://ygxb.ac.cn/zh/article/doi/10.11834/jrs.20210563>.
YANG Xing, CHI Yue, ZHOU Yatong, et al. Spectral-spatial attention bilateral network for hyperspectral image classification[J/OL]. Journal of Remote Sensing, 2021, [2022-08-10]. <http://ygxb.ac.cn/zh/article/doi/10.11834/jrs.20210563>.
- [6] 赵伍迪, 李山山, 李安, 等. 结合深度学习的高光谱与多源遥感数据融合分类[J]. 遥感学报, 2021, 25(7): 1489-1502.
ZHAO Wudi, LI Shanshan, LI An, et al. Deep fusion of hyperspectral images and multi-source remote sensing data for classification with convolutional neural network[J]. National Remote Sensing Bulletin, 2021, 25(7): 1489-1502.
- [7] 魏祥坡, 余旭初, 张鹏强, 等. 联合局部二值模式的CNN高光谱图像分类[J]. 遥感学报, 2020, 24(8): 1000-1009.
WEI Xiangpo, YU Xuchu, ZHANG Pengqiang, et al. CNN with local binary patterns for hyperspectral images classification[J]. Journal of Remote Sensing, 2020, 24(8): 1000-1009.
- [8] HANG Renlong, LIU Qingshan, HONG Danfeng, et al. Cascaded recurrent neural networks for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(8): 5384-5394.
- [9] ZHOU Feng, HANG Renlong, LIU Qingshan, et al. Hyperspectral image classification using spectral-spatial LSTMs[J]. Neurocomputing, 2019, 328(7): 39-47.
- [10] CHEN Yushi, JIANG Hanlu, LI Chunyang, et al. Deep feature extraction and classification of hyperspectral images based on convolutional neural networks[J]. IEEE

- Transactions on Geoscience and Remote Sensing, 2016, 54(10): 6232-6251.
- [11] 刘冰, 余旭初, 张鹏强, 等. 联合空-谱信息的高光谱影像深度三维卷积网络分类[J]. 测绘学报, 2019, 48(1): 53-63. DOI: 10.11947/j.AGCS.2019.20170578.
- LIU Bing, YU Xuchu, ZHANG Pengqiang, et al. Deep 3D convolutional network combined with spatial-spectral features for hyperspectral image classification[J]. Acta Geodaetica et Cartographica Sinica, 2019, 48(1): 53-63. DOI: 10.11947/j.AGCS.2019.20170578.
- [12] 高奎亮, 余旭初, 宋治杭, 等. 联合空谱信息的高光谱影像深度胶囊网络分类[J]. 遥感学报, 2021, 25(6): 1257-1269.
- GAO Kuiliang, YU Xuchu, SONG Zhihang, et al. Deep capsule network combined with spatial-spectral information for hyperspectral image classification[J]. National Remote Sensing Bulletin, 2021, 25(6): 1257-1269.
- [13] KEMKER R, KANAN C. Self-taught feature learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(5): 2693-2705.
- [14] ZHANG Mingyang, GONG Maoguo, HE Haibo, et al. Symmetric all convolutional neural-network-based unsupervised feature extraction for hyperspectral images classification[J]. IEEE Transactions on Cybernetics, 2022, 52(5): 2981-2993.
- [15] ZHANG Shuyu, XU Meng, ZHOU Jun, et al. Unsupervised spatial-spectral CNN-based feature learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5524617.
- [16] MEI Shaohui, JI Jingyu, GENG Yunhao, et al. Unsupervised spatial-spectral feature learning by 3D convolutional autoencoder for hyperspectral classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(9): 6808-6820.
- [17] ZHANG Mingyang, GONG Maoguo, MAO Yishun, et al. Unsupervised feature extraction in hyperspectral images based on Wasserstein generative adversarial network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(5): 2669-2688.
- [18] CHEN Ting, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C] // Proceedings of the 37th International Conference on Machine Learning. New York: ACM Press, 2020: 1597-1607.
- [19] ZHANG Suhua, CHEN Zhikui, WANG Dan, et al. Cross-domain few-shot contrastive learning for hyperspectral images classification[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [20] ZHU Mingzhen, FAN Jiayuan, YANG Qihang, et al. SC-EADNet: a self-supervised contrastive efficient asymmetric dilated network for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5519517.
- [21] HOU Sikang, SHI Hongye, CAO Xianghai, et al. Hyperspectral imagery classification based on contrastive learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5521213.
- [22] ZHAO Lin, LUO Wenqiang, LIAO Qiming, et al. Hyperspectral image classification with contrastive self-supervised learning under limited labeled samples[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 6008205.
- [23] XU Huilin, HE Wei, ZHANG Liangpei, et al. Unsupervised spectral-spatial semantic feature learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5526714.
- [24] ZHONG Yanfei, HU Xin, LUO Chang, et al. WHU-Hi: UAV-borne hyperspectral with high spatial resolution (H^2) benchmark datasets and classifier for precise crop identification based on deep convolutional neural network with CRF[J]. Remote Sensing of Environment, 2020, 250: 112012.
- [25] HANG Renlong, ZHOU Feng, LIU Qingshan, et al. Classification of hyperspectral images via multitask generative adversarial networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(2): 1424-1436.

(责任编辑: 张琳)

收稿日期: 2022-08-10

修回日期: 2023-04-04

第一作者简介: 杭仁龙(1988—), 男, 博士, 副教授, 主要研究方向为模式识别与遥感图像分析。

First author: HANG Renlong (1988—), male, PhD, associate professor, majors in pattern recognition and remote sensing image analysis.

E-mail: renlong_hang@163.com

通信作者: 刘青山

Corresponding author: LIU Qingshan

E-mail: qslu@nuist.edu.cn